



Ch.8 군집화 (2)

06 토픽 모델링(Topic Modeling) - 20 뉴스그룹

토픽 모델링(Topic Modeling) : 문서 집합에 숨어 있는 주제 찾아내는 것

- 숨겨진 주제를 효과적으로 표현할 수 있는 중심 단어를 함축적으로 추출
- LSA(Latent Semantic Analysis) & LDA(Latent Dirichlet Allocation)
- 20가지 주제의 뉴스그룹 데이터에 토픽 모델링 적용

07 문서 군집화 소개와 실습(Opinion Review 데이터 세트)

▼ 문서 군집화 개념

문서 군집화(Document Clustering) : 비슷한 텍스트 구성의 문서를 군집화(Clustering)

- 동일한 군집에 속하는 문서를 같은 카테고리 소속으로 분류 가능
- 학습 데이터 세트가 필요 없는 비지도학습 기반

▼ Opinion Review 데이터 세트를 이용한 문서 군집화 수행하기

- 문서 군집화를 이용해 각 리뷰 분류하기


▼ 군집별 핵심 단어 추출하기

- 각 군집을 구성하는 핵심단어에 어떤 것이 있는 지 확인

08 문서 유사도


▼ 문서 유사도 측정 방법 - 코사인 유사도

- 문서와 문서 간 유사도 비교 - 일반적으로 코사인 유사도(Cosine Similarity) 사용
- **코사인 유사도** : 벡터의 상호 방향성이 얼마나 유사한 지에 기반하여 벡터 간의 유사도 비교
- 두 벡터 사이의 사잇각 구해서 얼마나 유사한지 수치로 적용



▼ 두 벡터 사잇각

[두 벡터의 사잇각에 따른 상호 관계]



- **두 벡터 A와 B의 내적 값** : 두 벡터의 크기를 곱한 값의 코사인 각도 값 곱한 것

$$A \cdot B = \|A\| \|B\| \cos \theta$$

$$\text{similarity} = \cos \theta = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

- **코사인 유사도가 문서의 유사도 비교에 많이 사용되는 이유**
 1. 문서를 피처 벡터화 변환하면 차원이 매우 많은 희소 행렬이 되기 쉬움
 2. 문서가 매우 긴 경우 단어 빈도수 많음 → 공정한 비교 불가

▼ Opinion Review 데이터 세트를 이용한 문서 유사도 측정

- Opinion Review 데이터 세트를 이용해 문서 간 유사도 측정하기

09 한글 텍스트 처리 - 네이버 영화 평점 감성 분석

▼ 한글 NLP 처리의 어려움

- 한글 언어 처리 - 영어 등의 라틴어 처리보다 어려움
 1. '띄어쓰기'

- 한글 - 띄어쓰기 잘못하면 의미가 왜곡되어 전달 가능/띄어쓰기 어려움
- 영어 - 띄어쓰기 잘못하면 잘못된 단어로 인식/띄어쓰기 쉬움

2. '다양한 조사'

- 조사 : 주어나 목적어를 위해 추가됨, 어근 추출 등의 전처리 시 제거가 까다로움

▼ KoNLPy 소개

KoNLPy - 파이썬의 대표적인 한글 형태소 패키지

형태소 - '단어로서 의미를 가지는 최소 단위'

형태소 분석 - 말뭉치를 이러한 형태소 어근 단위로 쪼개고 각 형태소에 품사 태깅을 부착하는 작업

KoNLPy - 기존의 잘 만들어진 한글 형태소 엔진을 파이썬 래퍼(Wrapper) 기반으로 재작성한 패키지

기존의 엔진 그대로 유지한 채 파이썬 기반에서 인터페이스 제공 → 검증된 패키지의 안정성 유지 가능

▼ 데이터 로딩

네이버 영화 평점 데이터를 깃허브에서 로딩하여 실습 진행