





Ch.7 군집화

01 K-평균 알고리즘 이해

K-평균 : 군집화(Clustering)에서 가장 일반적으로 사용되는 알고리즘

⇒ 군집 중심(Centroid)이라는 특정한 지점 선택 → 중심에 가장 가까운 포인트 선택

[K-평균 과정]



[K-평균 장점]

- 일반적 군집화에서 가장 많이 활용되는 알고리즘
- 알고리즘이 쉽고 간결

[K-평균 단점]

- 거리 기반 알고리즘 → 속성 개수 많을 경우 군집화 정확도 하락
- 반복 횟수 많을 경우 수행시간 느려짐
- 몇 개 군집 선택해야 하는지 가이드 어려움

▼ 사이킷런 KMeans 클래스 소개

사이킷런 패키지 → KMeans 클래스 제공

[중요 파라미터]

KMeans 초기화 파라미터 중 가장 중요한 파라미터는 `n_clusters`이며, 이는 군집화할 개수, 즉 군집 중심점의 개수를 의미합니다.

`init`는 초기에 군집 중심점의 좌표를 설정할 방식을 말하며 보통은 임의로 중심을 설정하지 않고 일반적으로 `k-means++` 방식으로 최초 설정합니다.

`max_iter`는 최대 반복 횟수이며, 이 횟수 이전에 모든 데이터의 중심점 이동이 없으면 종료합니다.

[KMeans 객체 주요 속성 정보]

`labels_`: 각 데이터 포인트가 속한 군집 중심점 레이블

`cluster_centers_`: 각 군집 중심점 좌표(Shape는 [군집 개수, 피쳐 개수]). 이를 이용하면 군집 중심점 좌표가 어디인지 시각화할 수 있습니다.

▼ K-평균을 이용한 붓꽃 데이터 세트 군집화

- 붓꽃 데이터를 이용해 K-평균 군집화 수행
- 붓꽃의 꽃받침(sepal)과 꽃잎(petal) 길이와 너비에 따른 품종 분류하는 데이터 세트

▼ 군집화 알고리즘 테스트를 위한 데이터 생성

- 군집화 알고리즘 테스트를 위한 간단한 데이터 생성기 제공
- **make_blobs() & make_classification() API**
⇒ 여러 개의 클래스에 해당하는 데이터 세트 생성 → 하나의 클래스에 여러 개의 군집 분포되게 생성
- **make_blobs()** : 개별 군집의 중심점 & 표준 편차 제어 기능 추가 → '분류'에도 사용
- **make_classification()** : 노이즈 포함한 데이터 생성에 유용 → '분류'에도 사용
- **make_circle(), make_moon() API** : 중심 기반의 군집화로 해결하기 어려운 데이터 세트 생성

[make_blobs() 호출 파라미터]

n_samples: 생성할 총 데이터의 개수입니다. 디폴트는 100개입니다.

n_features: 데이터의 피쳐 개수입니다. 시각화를 목표로 할 경우 2개로 설정해 보통 첫 번째 피쳐는 x 좌표, 두 번째 피쳐는 y 좌표상에 표현합니다.

centers: int 값, 예를 들어 3으로 설정하면 군집의 개수를 나타냅니다. 그렇지 않고 ndarray 형태로 표현할 경우 개별 군집 중심점의 좌표를 의미합니다.

cluster_std: 생성될 군집 데이터의 표준 편차를 의미합니다. 만일 float 값 0.8과 같은 형태로 지정하면 군집 내에서 데이터가 표준편차 0.8을 가진 값으로 만들어집니다. [0.8, 1.2, 0.6]과 같은 형태로 표현되면 3개의 군집에서 첫 번째 군집 내 데이터의 표준편차는 0.8, 두 번째 군집 내 데이터의 표준 편차는 1.2, 세 번째 군집 내 데이터의 표준편차는 0.6으로 만듭니다. 군집별로 서로 다른 표준 편차를 가진 데이터 세트를 만들 때 사용합니다.

02 군집 평가(Cluster Evaluation)

- 대부분의 군집화 데이터 세트 : 비교할 만한 타깃 레이블 X
- 군집화 : 분류와 유사해 보이지만, 매우 다름

▼ 실루엣 분석의 개요

- 대표적인 군집화 평가 방법
- 각 군집 간의 거리가 얼마나 효율적으로 분리되어 있는지 나타냄


→ 다른 군집과의 거리는 멀고, 동일 군집끼리의 데이터는 뭉쳐질수록 효율적!

→ 개별 군집은 비슷한 정도의 여유공간을 가지고 떨어져짐!

- 실루엣 계수(silhouette coefficient) 기반

→ 개별 데이터가 가지는 군집화 지표

→ 같은 군집 내의 데이터와 얼마나 가깝게 군집화되어 있고, 다른 군집의 데이터와는 얼마나 멀리 분리되어 있는지 나타내는 지표



- i 번째 데이터 포인트의 실루엣 계수 값 $s(i)$

$$s(i) = \frac{(b(i) - a(i))}{(\max(a(i), b(i)))}$$

→ -1 ~ 1 사이의 값

→ 1로 가까워질수록 더 멀리 떨어져짐, 0에 가까울수록 근처의 군집과 가까워짐

→ - 값은 아예 다른 군집에 포인트가 할당되었다는 뜻

[좋은 군집화의 기준]

1. 전체 실루엣 계수의 평균값, 즉 사이킷런의 `silhouette_score()` 값은 0 ~ 1 사이의 값을 가지며, 1에 가까울수록 좋습니다.
2. 하지만 전체 실루엣 계수의 평균값과 더불어 개별 군집의 평균값의 편차가 크지 않아야 합니다. 즉, 개별 군집의 실루엣 계수 평균값이 전체 실루엣 계수의 평균값에서 크게 벗어나지 않는 것이 중요합니다. 만약 전체 실루엣 계수의 평균값은 높지만, 특정 군집의 실루엣 계수 평균값만 유난히 높고 다른 군집들의 실루엣 계수 평균값은 낮으면 좋은 군집화 조건이 아닙니다.

▼ 붓꽃 데이터 세트를 이용한 군집 평가

- 붓꽃 데이터 세트의 군집화 결과를 실루엣 분석으로 평가
- `sklearn.metrics` 모듈의 `silhouette_samples()`와 `silhouette_score()` 이용


▼ 군집별 평균 실루엣 계수의 시각화를 통한 군집 개수 최적화 방법

- “전체 데이터의 평균 실루엣 계수 값이 높다” - 무조건 좋은 군집화는 아님!
- 개별 군집별로 적당히 분리된 거리를 유지 & 군집 내의 데이터가 서로 뭉쳐 있는 경우 - 적절한 군집 개수!

[군집 개수 2개인 경우]

1번 군집 : 모든 데이터가 평균 실루엣 계수 값 이상

0번 군집 : 평균보다 적은 데이터 값 존재




군집이 2개일 경우 평균 실루엣 계수 값: 0.704

[군집 개수 3개인 경우]

1번, 2번 군집 : 평균보다 높은 실루엣 계수 값

0번 군집 : 모두 평균보다 낮은 값



[군집 개수 4개인 경우]


1번 군집 : 모든 데이터가 평균보다 높은 계수 값

0번, 2번 군집 : 절반 이상이 평균보다 높은 계수 값

3번 군집 : 약 1/3 정도가 평균보다 높은 계수 값

→ 군집이 2개인 경우보다는 평균 실루엣 값 작음

→ But, 4개인 경우가 가장 이상적인 군집 개수



[visualize_silhouette() 함수]

- 군집 개수를 변화시키면서 K-평균 군집 수행 시에 개별 군집별 평균 실루엣 계수 값 시각화 → 군집 정하는 데 도움

- 내부 파라미터

첫 번째 파라미터 : 여러 개의 군집 개수를 리스트로 가짐

두 번째 파라미터 : 피쳐 데이터 세트

03 평균 이동

▼ 평균 이동(Mean Shift)의 개요


K-평균

- 중심을 군집의 중심으로 지속적으로 움직이며 군집화 수행
- 중심에 소속된 데이터 평균 거리 중심으로 이동

평균 이동(Mean Shift)

- 중심을 군집의 중심으로 지속적으로 움직이며 군집화 수행
- 중심을 데이터가 모여 있는 밀도가 가장 높은 곳으로 이동


- 데이터 중심점을 이용해 군집 중심점 찾기
- 확률 밀도 함수(probability density function) 이용
- 군집 중심점 : 확률 밀도 함수가 피크인 점 → KDE(Kernel Density Estimation) 이용
- 주변 데이터와의 거리 값을 KDE 함수 값으로 입력 → 반환 값을 현재 위치에서 업데이트 하면서 이동
- 전체 데이터에 반복적으로 적용 → 데이터의 군집 중심점 찾기




[KDE(Kernel Density Estimation)]

- 커널 함수를 통해 변수의 확률 밀도 함수 추정

- 관측된 데이터에 커널 함수 적용 → 모두 더하기 → 데이터 건수로 나누기
- Ex) 가우시안 분포 함수



$$\text{KDE} = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$



[PDF(Probability Density Function)]

- 확률 변수의 분포 나타내는 함수
- Ex) 정규 분포 함수, 감마 분포, t-분포
- 변수의 특성, 확률 분포 등 "변수에 대한 값" 확인 가능


04 GMM(Gaussian Mixture Model)

▼ GMM(Gaussian Mixture Model) 소개

- 군집화를 적용하고자 하는 데이터가 여러 개의 가우시안 분포를 가진 데이터들이 섞여 생성된 것이라는 가정하에 군집화 수행


[정규분포]

- 좌우 대칭형의 종(Bell) 형태를 가진 연속 확률 함수
- 평균 μ 를 중심으로 높은 데이터 분포도
- 평균 : 0 // 표준편차 : 1




[GMM 과정]


가정 : 세 개의 가우시안 분포 A, B, C를 가진 데이터 세트 존재



1. 세 개의 정규 분포 합치기



2. 여러 개의 정규 분포 곡선 추출, 개별 데이터가 어떤 정규 분포에 속하는지 결정



⇒ "모수 추정"

- 개별 정규 분포의 평균과 분산
- 각 데이터가 어떤 정규 분포에 해당되는지의 확률

- EM(Expectation and Maximization) 방법 적용


▼ GMM을 이용한 붓꽃 데이터 세트 군집화

- GMM : 확률 기반 군집화 // K-평균 : 거리 기반 군집화
- 붓꽃 데이터 세트로 군집화 수행 → 양쪽 방식 비교

▼ GMM과 K-평균의 비교

- KMeans : 원형 범위에서 군집화 수행 (원형일수록 효율 증가)

Kmeans는 원형의 범위를 가지고 Clustering을 수행



- But, 데이터가 원형 범위가 X ?


KMeans - 데이터가 길쭉한 차원형으로 늘어진 경우 군집화 잘 수행 X

GMM - KMeans보다 유연하게 데이터 세트에 적용, but, 수행시간 길

05 DBSCAN

▼ DBSCAN(Density Based Spatial Clustering of Applications with Noise) 개요

- 밀도 기반 군집화의 대표적인 알고리즘
- 간단하고 직관적인 알고리즘 → 복잡한 데이터 세트에도 효과적



- 중요한 두 가지 파라미터

입실론 주변 영역(epsilon): 개별 데이터를 중심으로 입실론 반경을 가지는 원형의 영역입니다.

최소 데이터 개수(min points): 개별 데이터의 입실론 주변 영역에 포함되는 타 데이터의 개수입니다.

- 데이터 포인트 정의

핵심 포인트(Core Point): 주변 영역 내에 최소 데이터 개수 이상의 타 데이터를 가지고 있을 경우 해당 데이터를 핵심 포인트라고 합니다.


이웃 포인트(Neighbor Point): 주변 영역 내에 위치한 타 데이터를 이웃 포인트라고 합니다.

경계 포인트(Border Point): 주변 영역 내에 최소 데이터 개수 이상의 이웃 포인트를 가지고 있지 않지만 핵심 포인트를 이웃 포인트로 가지고 있는 데이터를 경계 포인트라고 합니다.


잡음 포인트(Noise Point): 최소 데이터 개수 이상의 이웃 포인트를 가지고 있지 않으며, 핵심 포인트도 이웃 포인트로 가지고 있지 않는 데이터를 잡음 포인트라고 합니다.

[DBSCAN 과정]


1. 다음 그림과 같이 P1에서 P12까지 12개의 데이터 세트에 대해서 DBSCAN 군집화를 적용하면서 주요 개념을 설명하겠습니다. 특정 입실론 반경 내에 포함될 최소 데이터 세트를 6개로(자기 자신의 데이터를 포함) 가정하겠습니다.




2. P1 데이터를 기준으로 입실론 반경 내에 포함된 데이터가 7개(자신은 P1, 이웃 데이터 P2, P6, P7, P8, P9, P11)로 최소 데이터 5개 이상을 만족하므로 P1 데이터는 핵심 포인트(Core Point)입니다.




3. 다음으로 P2 데이터 포인트를 살펴보겠습니다. P2 역시 반경 내에 6개의 데이터(자신은 P2, 이웃 데이터 P1, P3, P4, P9, P10)를 가지고 있으므로 핵심 포인트입니다.




4. 핵심 포인트 P1의 이웃 데이터 포인트 P2 역시 핵심 포인트일 경우 P1에서 P2로 연결해 직접 접근이 가능합니다.




5. 특정 핵심 포인트에서 직접 접근이 가능한 다른 핵심 포인트를 서로 연결하면서 군집화를 구성합니다. 이러한 방식으로 점차적으로 군집(Cluster) 영역을 확장해 나가는 것이 DBSCAN 군집화 방식입니다.



6. P3 데이터의 경우 반경 내에 포함되는 이웃 데이터는 P2, P4로 2개이므로 군집으로 구분할 수 있는 핵심 포인트가 될 수 없습니다. 하지만 이웃 데이터 중에 핵심 포인트인 P2를 가지고 있습니다. 이처럼 자신은 핵심 포인트가 아니지만, 이웃 데이터로 핵심 포인트를 가지고 있는 데이터를 경계 포인트(Border Point)라고 합니다. 경계 포인트는 군집의 외곽을 형성합니다.



7. 다음 그림의 P5와 같이 반경 내에 최소 데이터를 가지고 있지도 않고, 핵심 포인트 또한 이웃 데이터로 가지고 있지 않는 데이터를 잡음 포인트(Noise Point)라고 합니다.



• 주요한 초기화 파라미터

eps: 입실론 주변 영역의 반경을 의미합니다.

min_samples: 핵심 포인트가 되기 위해 입실론 주변 영역 내에 포함돼야 할 데이터의 최소 개수를 의미합니다(자신의 데이터를 포함합니다. 위에서 설명한 min points + 1).

▼ DBSCAN 적용하기 - 붓꽃 데이터 세트

- DBSCAN 알고리즘으로 붓꽃 데이터 세트 군집화

▼ DBSCAN 적용하기 - make_circles() 데이터 세트

- 복잡한 기하학적 분포를 가지는 데이터 세트에서 DBSCAN & 타 알고리즘 비교

06 군집화 실습 - 고객 세그먼테이션

▼ 고객 세그먼테이션의 정의와 기법

- 다양한 기준으로 고객을 분류하는 기법
- CRM / 마케팅의 중요 기반 요소

[고객 분류 요소]

1. 개인의 신상 데이터 : 지역/결혼 여부/성별/소득
2. 어떤 상품을 얼마나 많은 비용으로 얼마나 자주 사용하는가
3. 기업 - 얼마나 많은 매출을 발생하느냐

[고객 세그먼테이션의 주요 목표]

: 타겟 마케팅

- 고객을 여러 특성에 맞게 세분화 → 맞춤형 마케팅이나 서비스 제공
- Ex) 기업의 마케팅 : 고객의 상품 구매 이력에서 출발

[RFM 기법]

- 어떤 요소를 기반으로 군집화할 것 인지 결정하는 기법

RECENCY (R): 가장 최근 상품 구입 일에서 오늘까지의 기간

FREQUENCY (F): 상품 구매 횟수

MONETARY VALUE (M): 총 구매 금액

▼ 데이터 세트 로딩과 데이터 클렌징

- Online Retail 파일 다운로드, 데이터 확인

▼ RFM 기반 데이터 가공

- 정제된 데이터 기반으로 고객 세그먼테이션 군집화를 RFM 기반으로 수행

▼ RFM 기반 고객 세그먼테이션

- 온라인 판매 데이터 세트의 칼럼별 히스토그램 확인
- 왜곡된 데이터 분포도에서 군집화 수행 시 어떤 현상 발생하는지 확인

07 정리

1. K-평균

- 거리 기반으로 군집 중심점을 이동시키면서 군집화를 수행
- 매우 쉽고 직관적인 알고리즘 → 군집화 애플리케이션에서 애용
- 복잡한 구조를 가지는 데이터 세트 적용에 한계 존재
- 군집의 개수를 최적화하기 어려움
- 군집 평가에 실루엣 계수 이용

2. 평균 이동(Mean Shift)

- K-평균과 유사, 거리 중심 X, 데이터 밀도가 가장 높은 쪽으로 군집 중심점을 이동하면서 군집화를 수행
- 컴퓨터 비전 영역에서 이미지나 영상 데이터에서 특정 개체를 구분하거나 움직임을 추적하는 데 뛰어난 역할을 수행하는 알고리즘

3. GMM(Gaussian Mixture Model) 군집화

- 군집화를 적용하고자 하는 데이터가 여러 개의 가우시안 분포(Gaussian Distribution)모델을 섞어서 생성된 모델로 가정해 수행
- 데이터 세트에서 서로 다른 정규 분포 형태를 추출 → 다른 정규 분포를 가진 데이터 세트를 각각 군집화
- K-평균보다 유연하게 다양한 데이터 세트에 잘 적용

- 군집화를 위한 수행 시간이 오래 걸림

4. DBSCAN(Density Based Spatial Clustering of Applications with Noise)

- 밀도 기반 군집화의 대표적인 알고리즘
- 입실론 주변 영역 내에 포함되는 최소 데이터 개수의 충족 여부
 부에 따라 데이터 포인트를 핵심 포인트, 이웃 포인트, 경계 포인트, 잡음 포인트로 구분
- 특정 핵심 포인트에서 직접 접근이 가능한 다른 핵심 포인트를 서로 연결하면서 군집화를 구성
- 간단하고 직관적인 알고리즘
- 기하학적으로 복잡한 데이터 세트에도 효과적인 군집화 가능